


Ц. Тэнгис • CallPro Labs • 2026

БАРИМТАД ТУЛГУУРЛАСАН RAG ЧАТБОТ

Үйлдвэрлэлийн дадлагын тайлангийн хамгаалалт



БАЙГУУЛЛАГА БА МИНИЙ ОРОЛЦОО



CALLPRO LABS

CallPro-ийн AI чиглэлийн хөгжүүлэлт, монгол яриаг текст болгох загварын өгөгдөл бэлтгэдэг.

МИНИЙ ҮҮРЭГ

- 5–60 секундын аудио бичлэгийг сонсож текст болгон буулгасан
- Сул авиа болон зөв бичгийн дүрмийг бүрэн тэмдэглэсэн
- Өдөр тутмын ажлын зэрэгцээ RAG чатботын бие даасан төсөл хөгжүүлсэн



ТӨСЛИЙН ЗОРИЛГО

01

АСУУДАЛ

Байгууллагын PDF, журам, тайлангаас мэдээллийг гараар хайхад хугацаа их ордог. Түлхүүр үгийн хайлт нь өөр үгээр бичсэн ижил утгыг алдаж болно.

02

ШИЙДЭЛ

Хэрэглэгчийн баримтаас утгаар хайж, зөвхөн олдсон контекстээр хариулан, ашигласан эх сурвалжийг хамт харуулах RAG чатботын MVP бүтээх.

03



ХЭРЭГЖҮҮЛСЭН ДАРААЛАЛ



01

ШААРДЛАГА БА ЗОХИОМЖ

Асуудлыг тодорхойлж, web-API-өгөгдлийн сангийн архитектур болон хэрэглэгчийн тусгаарлалтыг төлөвлөсөн.

02

ТЕХНОЛОГИЙН СОНГОЛТ

React/Vite, Fastify, PostgreSQL + pgvector, Gemini, Expo-г MVP-ийн шаардлага болон зардалд тулгуурлан сонгосон.

03


ХЭРЭГЖҮҮЛЭЛТ БА ТУРШИЛТ

Индексжүүлэлт, хайлт, хариулт, нэвтрэлт, web/mobile клиент болон байршуулалтыг үе шаттай хийж шалгасан.


АРХИТЕКТУР БА ТЕХНОЛОГИЙН СОНГОЛТ

ЯАГААД ЭНЭ АРХИТЕКТУР ВЭ?

- Web болон mobile нэг Fastify API ашиглана
- PostgreSQL өгөгдөл ба 768 хэмжээст векторыг хамт хадгална
- Better Auth session-аар бүх хүсэлтийг user_id-аар тусгаарлана
- Gemini embedding болон хариулт үүсгэлтийг серверээс дуудна



RAG-Д СУРСАН ШИНЭ ОЙЛГОЛТУУД



CHUNK

Урт баримтыг давхцалтай жижиг хэсгүүдэд хуваана.

EMBEDDING

Текстийн утгыг 768 хэмжээст вектор болгоно.

RETRIEVAL + GROUNDING

Асуултад ойр хэсгийг хайж, зөвхөн олдсон контекстээр хариулна. Эх сурвалжийг хамт буцаана.



ТУРШИЛТ БА БОДИТ ҮР ДҮН

БАТАЛГААЖУУЛСАН

- PDF болон текст боловсруулалт
- Эх сурвалжтай grounded хариулт
- Web ба standalone Android APK
- Хоёр бүртгэлээр өгөгдлийн тусгаарлалт
- Azure + Cloudflare HTTPS байршуулалт

ШИЙДСЭН АСУУДЛУУД

- Кирилл баримт, латин асуултын threshold
- Gemini 429 квотод завсарлагатай дахин оролдлого
- Mobile boot loop ба API хаягийн сонголт
- Шинэ хувилбарын drain, backup, rollback

Хязгаарлалт: mobile UI болон анхны cold start-ыг сайжруулах шаардлагатай.

АНХААРАЛ ХАНДУУЛСАНД БАЯРЛАЛАА

ДҮГНЭЛТ

Баримтад тулгуурласан, эх сурвалжтай, олон хэрэглэгчийн web/mobile RAG системийг хөгжүүлж, бодит сервер болон Android төхөөрөмж дээр баталгаажуулсан.

Эзэмшсэн чадвар: RAG • pgvector • auth • Docker • CI/CD • cloud deployment