

## 1. Индексжүүлэлт (баримт нэмэгдэх үед)

Баримтууд  
(PDF, текст)

Хэсэглэлт  
(chunking)

Embedding  
загвар

Вектор  
хайлтын сан

## 2. Хайлт (асуулт бүрд)

Хэрэглэгчийн  
асуулт

Embedding  
загвар

асуултын вектор

Хамгийн ойр k хэсгийг  
косинус төстэй байдлаар  
олох

олдсон хэсгүүд (context)

## 3. Хариу үүсгэлт

Prompt =  
заавар + context + асуулт

Том хэлний  
загвар (LLM)

Хариулт  
+ эх сурвалжууд